

Notas de Aula  
03 - Amostra Aleatória Simples com Reposição

Amostra Aleatória Simples (AAS) é o método mais simples e mais importante para a seleção de uma amostra. Pode ser um plano próprio ou um estágio de um plano com vários estágios. Pode ser caracterizado por meio da definição operacional: “De uma lista de  $N$  unidades elementares, sorteiam-se com igual probabilidade  $n$  unidades”. Pode ser realizada com (AASc) ou sem (AASs) reposição, inicialmente iremos focar no cenário **com reposição**.

1. Distribuição de  $f_i$  e probabilidade de inclusão

Na AASc, sorteamos com reposição e igual probabilidade  $n$  elementos de  $\mathcal{U}$ . Isso equivale a  $n$  repetições independentes de um experimento com  $N$  resultados possíveis, cada um com probabilidade  $1/N$ .

**Distribuição de  $f_i$**

Seja  $f_i$  o número de vezes que o  $i$ -ésimo elemento aparece na amostra, então

$$f_i \sim \text{Binomial} \left( n, \frac{1}{N} \right),$$

com  $E(f_i) = n/N$  e  $\text{Var}(f_i) = n/N(1 - 1/N)$  e

$$(f_1, \dots, f_N) \sim \text{Multinomial} \left( n, \frac{1}{N}, \dots, \frac{1}{N} \right),$$

com  $\text{Cov}(f_i, f_j) = -n/N^2$ .

**Probabilidade de inclusão de primeira ordem**

$$\pi_i = 1 - \frac{(N-1)^n}{N^n}.$$

**Probabilidade de inclusão de segunda ordem**

$$\pi_{ij} = \frac{N^n - 2(N-1)^n + (N-2)^n}{N^n}.$$

2. A estatística  $t(\mathbf{s})$  e suas propriedades

A estatística  $t(\mathbf{s})$ , total da amostra, definida por

$$t(\mathbf{s}) = t = \sum_{i \in \mathbf{s}} Y_i$$

tem para o plano AASc as seguintes propriedades

$$E(t) = n\mu \quad \text{e} \quad \text{Var}(t) = n\sigma^2.$$

3. Estimação do total populacional  $\tau$

Com base nas propriedades do  $t$ , podemos deduzir um estimador não viesado para o total populacional.

O estimador

$$\hat{\tau} = \frac{N}{n}t(s)$$

é um estimador não viesado para o total populacional  $\tau$ , pois  $E(\hat{\tau}) = \tau$  e a sua variância é dada por  $Var(\hat{\tau}) = N^2\sigma^2/n$ .

#### 4. Estimação da média populacional $\mu$

Da relação entre a média e o total populacionais e amostrais, resulta que

$$\bar{y} = \frac{t(s)}{n}$$

é um estimador não viesado para a média populacional  $\mu$ , pois  $E(\bar{y}) = \mu$  e a sua variância é  $Var(\bar{y}) = \sigma^2/n$ .

#### 5. Estimação da variância populacional $\sigma^2$

Dentro do plano AASc, a estatística

$$s^2 = \frac{1}{n-1} \sum_{i \in s} (Y_i - \bar{y})^2$$

é um estimador não viesado da variância populacional  $\sigma^2$ .

Deste modo, podemos fornecer estimadores não viesados para as variâncias dos estimadores  $\hat{\tau}$  e  $\bar{y}$ , isto é,

$$\widehat{Var}(\hat{\tau}) = N^2 \frac{s^2}{n} \quad \text{e} \quad \widehat{Var}(\bar{y}) = \frac{s^2}{n}.$$

**Exercício 1:** Considere uma população com 3 elementos, cuja característica de interesse é a renda familiar. O parâmetro populacional é  $D = (12, 30, 18)$ . Para esta população  $\tau = 60$ ,  $\mu = 20$  e  $\sigma^2 = 56$ . Definido o plano amostral AASc, com  $n = 2$ , defina: (i) o espaço amostral induzido pelo plano amostral. (ii) as distribuições amostrais de  $\hat{\tau}$ ,  $\bar{y}$  e  $s^2$ . (iii) com base nas distribuições amostrais calcule  $E(\hat{\tau})$ ,  $Var(\hat{\tau})$ ,  $E(\bar{y})$ ,  $Var(\bar{y})$  e  $E(s^2)$ .

#### 6. Normalidade assintótica e intervalos de confiança

Pelo TLC, temos as seguintes distribuições assintóticas

$$\frac{\hat{\tau} - E(\hat{\tau})}{DP(\hat{\tau})} \sim N(0, 1) \quad \text{e} \quad \frac{\bar{y} - E(\bar{y})}{DP(\bar{y})} \sim N(0, 1).$$

Sob AASc, resulta que

$$\frac{\hat{\tau} - \tau}{N\sqrt{\sigma^2/n}} \sim N(0, 1) \quad \text{e} \quad \frac{\bar{y} - \mu}{\sqrt{\sigma^2/n}} \sim N(0, 1).$$

A partir destas distribuições assintóticas, podemos obter intervalos de confiança com nível de confiança de aproximadamente igual a  $1 - \alpha$ . Para o total populacional temos

$$IC(\tau, (1 - \alpha)\%) = \left( \hat{\tau} - z_{\alpha/2} N \sqrt{\frac{s^2}{n}}; \hat{\tau} + z_{\alpha/2} N \sqrt{\frac{s^2}{n}} \right),$$

e para a média populacional temos

$$IC(\mu, (1 - \alpha)\%) = \left( \bar{y} - z_{\alpha/2} \sqrt{\frac{s^2}{n}}; \bar{y} + z_{\alpha/2} \sqrt{\frac{s^2}{n}} \right).$$

#### 7. Determinação do tamanho da amostra

### Controlando o erro absoluto para o estimador da média

Vamos determinar o tamanho da amostra para que o estimador  $\bar{y}$  tenha erro máximo igual a  $B$  para um nível de confiança  $1 - \alpha$ , isto é,

$$P(|\bar{y} - \mu| \leq B) \approx 1 - \alpha.$$

Facilmente derivamos da expressão acima que

$$n = \frac{\sigma^2}{(B/z_\alpha)^2} = \frac{\sigma^2}{D}.$$

### Controlando o erro relativo para o estimador da média

Vamos determinar o tamanho da amostra para que o estimador  $\bar{y}$  tenha erro máximo relativo igual a  $B$  para um nível de confiança  $1 - \alpha$ , isto é,

$$P\left(\left|\frac{\bar{y} - \mu}{\mu}\right| \leq B\right) \approx 1 - \alpha.$$

Facilmente derivamos da expressão acima que

$$n = \frac{CV^2}{D}.$$

Como ficaria para o total?

## 8. Estimação de proporções

Consideremos o caso em que se tem interesse na estimação da proporção de elementos da população que possuem determinada característica. Neste caso, temos associada a cada elemento da população a variável

$$Y_i = \begin{cases} 1, & \text{se o elemento } i \text{ possui a característica} \\ 0, & \text{caso contrário.} \end{cases}$$

A proporção populacional, o parâmetro de interesse nesse caso é

$$p = \frac{1}{N} \sum_{i=1}^N Y_i = \mu,$$

ou seja, a média da variável de interesse é a proporção populacional. A variância populacional neste caso será

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (Y_i - \mu)^2 = \frac{1}{N} \sum_{i=1}^N (Y_i - p)^2 = \frac{1}{N} \sum_{i=1}^N Y_i^2 - p^2 = \frac{1}{N} \sum_{i=1}^N Y_i - p^2 = p - p^2 = p(1 - p).$$

### Estimador não viciado para a proporção

Como o parâmetro de interesse é a média, sabemos que a média amostral é um estimador não viciado. Neste caso, a média amostral é a proporção amostral

$$\hat{p} = \frac{1}{n} \sum_{i \in S} Y_i$$

e a sua variância é dada por

$$Var(\hat{p}) = \frac{\sigma^2}{n} = \frac{p(1 - p)}{n}.$$

Um estimador não viciado para  $\sigma^2$  é

$$s^2 = \frac{n}{n-1} \hat{p}(1-\hat{p}),$$

logo um estimador para a variância de  $\hat{p}$  é dado por

$$\widehat{Var}(\hat{p}) = \frac{\hat{p}(1-\hat{p})}{n-1}.$$

### Intervalo de confiança

Pelo TLC, temos que

$$\frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \sim N(0, 1)$$

e um intervalo de confiança de nível de confiança de aproximadamente  $1 - \alpha$  é dado por

$$IC(p, (1 - \alpha)\%) = \left( \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n-1}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n-1}} \right),$$

como  $\hat{p}(1-\hat{p}) \leq 1/4$ , um intervalo de confiança conservador é dado por

$$IC(p, (1 - \alpha)\%) = \left( \hat{p} - z_{\alpha/2} \sqrt{\frac{1}{4(n-1)}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{1}{4(n-1)}} \right),$$

### Tamanho da amostra

Como no caso da média, podemos considerar o tamanho da amostra  $n$ , de tal forma que

$$P(|\hat{p} - p| \leq B) \approx 1 - \alpha,$$

e obtemos um tamanho de amostra dado por  $n = \frac{p(1-p)}{D}$  e se considerarmos um cenário mais conservador  $n = 1/(4D)$ .

### 9. Otimalidade de $\bar{y}$ na AASc

Considere as variáveis  $y_1, \dots, y_n$ , isto é, a variável  $y_i$  assume os valores  $Y_1, \dots, Y_N$ , com probabilidade  $1/N$ , ou seja,  $P(y_i = Y_j) = 1/N, j = 1, \dots, N$ . No plano AASc as variáveis  $y_i$  são independentes.

Estimador linear: um estimador linear de  $\mu$  é uma função  $d_s$  dada por

$$\bar{y}_{sl} = \sum_{i=1}^n l_i y_i,$$

em que os  $l_i$  são constantes conhecidas.

Um estimador  $\bar{y}_{sl}$  é não viciado para  $\mu$  se e somente se

$$\sum_{i=1}^n l_i = 1.$$

Com relação à AASc, na classe dos estimadores lineares não viciados,  $\bar{y}$  é o de menor variância.