

Notas de Aula  
04 - Amostra Aleatória Simples sem Reposição

1. Distribuição de  $f_i$  e probabilidade de inclusão

Na AASs, sorteamos, sem reposição e igual probabilidade  $n$  elementos de  $\mathcal{U}$ . Assim cada elemento aparece uma única vez na amostra. Vamos considerar amostras ordenadas, para manter a coerência com o estudo da AASc.

**Distribuição de  $f_i$**

Seja  $f_i$  o número de vezes que o  $i$ -ésimo elemento aparece na amostra, então

$$f_i \sim \text{Bernoulli}(\pi_i),$$

com  $E(f_i) = \pi_i$  e  $\text{Var}(f_i) = \pi_i(1 - \pi_i)$ .

**Probabilidade de inclusão de primeira ordem**

$$\pi_i = \frac{n}{N}.$$

**Probabilidade de inclusão de segunda ordem**

$$\pi_{ij} = \frac{n(n-1)}{N(N-1)}.$$

A covariância entre  $f_i$  e  $f_j$  é dada por

$$\text{Cov}(f_i, f_j) = -\frac{n}{N^2} \frac{N-n}{N-1}.$$

Esses mesmos resultados valeriam em caso de amostras não ordenadas?

2. A estatística  $t(s)$  e suas propriedades

A estatística  $t(s)$ , total da amostra, definida por

$$t(s) = t = \sum_{i \in s} Y_i = \sum_{i=1}^N f_i Y_i$$

tem para o plano AASs as seguintes propriedades

$$E(t) = n\mu \quad \text{e} \quad \text{Var}(t) = n(1-f)S^2,$$

em que  $f = n/N$  denominada fração amostral.

3. Estimação do total populacional  $\tau$

Com base nas propriedades do  $t$ , podemos deduzir um estimador não viesado para o total populacional.

O estimador

$$\hat{\tau} = \frac{N}{n} t(s)$$

é um estimador não viesado para o total populacional  $\tau$ , pois  $E(\hat{\tau}) = \tau$  e a sua variância é dada por  $\text{Var}(\hat{\tau}) = N^2(1-f)S^2/n$ .

#### 4. Estimação da média populacional $\mu$

Da relação entre a média e o total populacionais e amostrais, resulta que

$$\bar{y} = \frac{t(s)}{n}$$

é um estimador não viesado para a média populacional  $\mu$ , pois  $E(\bar{y}) = \mu$  e a sua variância é  $Var(\bar{y}) = (1-f)S^2/n$ .

#### 5. Estimação da variância populacional $S^2$

Dentro do plano AASs, a estatística

$$s^2 = \frac{1}{n-1} \sum_{i \in S} (Y_i - \bar{y})^2$$

é um estimador não viesado da variância populacional  $S^2$ .

Deste modo, podemos fornecer estimadores não viesados para as variâncias dos estimadores  $\hat{\tau}$  e  $\bar{y}$ , isto é,

$$\widehat{Var}(\hat{\tau}) = N^2(1-f)\frac{s^2}{n} \quad \text{e} \quad \widehat{Var}(\bar{y}) = (1-f)\frac{s^2}{n}.$$

**Exercício 1:** Considere uma população com 3 elementos, cuja característica de interesse é a renda familiar. O parâmetro populacional é  $D = (12, 30, 18)$ . Para esta população  $\tau = 60$ ,  $\mu = 20$  e  $S^2 = 84$ . Definido o plano amostral AASs, com  $n = 2$ , defina: (i) o espaço amostral induzido pelo plano amostral. (ii) as distribuições amostrais de  $\hat{\tau}$ ,  $\bar{y}$  e  $s^2$ . (iii) com base nas distribuições amostrais calcule  $E(\hat{\tau})$ ,  $Var(\hat{\tau})$ ,  $E(\bar{y})$ ,  $Var(\bar{y})$ ,  $E(s^2)$ .

#### 6. Normalidade assintótica e intervalos de confiança

Pelo TLC, temos as seguintes distribuições assintóticas

$$\frac{\hat{\tau} - E(\hat{\tau})}{DP(\hat{\tau})} \sim N(0, 1) \quad \text{e} \quad \frac{\bar{y} - E(\bar{y})}{DP(\bar{y})} \sim N(0, 1).$$

Sob AASs, resulta que

$$\frac{\hat{\tau} - \tau}{N\sqrt{(1-f)S^2/n}} \sim N(0, 1) \quad \text{e} \quad \frac{\bar{y} - \mu}{\sqrt{(1-f)S^2/n}} \sim N(0, 1).$$

A partir destas distribuições assintóticas, podemos obter intervalos de confiança com nível de confiança de aproximadamente igual a  $1 - \alpha$ . Para o total populacional temos

$$IC(\tau, (1-\alpha)\%) = \left( \hat{\tau} - z_{\alpha/2} N \sqrt{(1-f)\frac{s^2}{n}}; \hat{\tau} + z_{\alpha/2} N \sqrt{(1-f)\frac{s^2}{n}} \right),$$

e para a média populacional temos

$$IC(\mu, (1-\alpha)\%) = \left( \bar{y} - z_{\alpha/2} \sqrt{(1-f)\frac{s^2}{n}}; \bar{y} + z_{\alpha/2} \sqrt{(1-f)\frac{s^2}{n}} \right).$$

#### 7. Determinação do tamanho da amostra

##### Controlando o erro absoluto para o estimador da média

Vamos determinar o tamanho da amostra para que o estimador  $\bar{y}$  tenha erro máximo igual a  $B$  para um nível de confiança  $1 - \alpha$ , isto é,

$$P(|\bar{y} - \mu| \leq B) \approx 1 - \alpha.$$

Facilmente derivamos da expressão acima que

$$n = \frac{1}{\frac{D}{S^2} + \frac{1}{N}},$$

em que  $D = B^2/z_{\alpha/2}^2$ .

### Controlando o erro relativo para o estimador da média

Vamos determinar o tamanho da amostra para que o estimador  $\bar{y}$  tenha erro máximo relativo igual a  $B$  para um nível de confiança  $1 - \alpha$ , isto é,

$$P\left(\left|\frac{\bar{y} - \mu}{\mu}\right| \leq B\right) \approx 1 - \alpha.$$

Facilmente derivamos da expressão acima que

$$n = \frac{1}{\frac{D}{CV^2} + \frac{1}{N}}.$$

Como ficaria para o total?

### 8. Estimação de proporções

Consideremos o caso em que se tem interesse na estimação da proporção de elementos da população que possuem determinada característica. Neste caso, temos associada a cada elemento da população a variável

$$Y_i = \begin{cases} 1, & \text{se o elemento } i \text{ possui a característica} \\ 0, & \text{caso contrário.} \end{cases}$$

A proporção populacional, o parâmetro de interesse nesse caso é

$$p = \frac{1}{N} \sum_{i=1}^N Y_i = \mu,$$

ou seja, a média da variável de interesse é a proporção populacional. A variância populacional neste caso será

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (Y_i - \mu)^2 = \frac{1}{N} \sum_{i=1}^N (Y_i - p)^2 = \frac{1}{N} \sum_{i=1}^N Y_i^2 - p^2 = \frac{1}{N} \sum_{i=1}^N Y_i - p^2 = p - p^2 = p(1 - p),$$

e

$$S^2 = \frac{N}{N-1} \sigma^2 = \frac{N}{N-1} p(1 - p)$$

### Estimador não viciado para a proporção

Como o parâmetro de interesse é a média, sabemos que a média amostral é um estimador não viciado. Neste caso, a média amostral é a proporção amostral

$$\hat{p} = \frac{1}{n} \sum_{i \in S} Y_i$$

e a sua variância é dada por

$$Var(\hat{p}) = (1 - f) \frac{S^2}{n} = \frac{N - n}{N - 1} \frac{p(1 - p)}{n}.$$

Um estimador não viciado para  $S^2$  é

$$s^2 = \frac{n}{n-1} \hat{p}(1 - \hat{p}),$$

logo um estimador para a variância de  $\hat{p}$  é dado por

$$\widehat{Var}(\hat{p}) = (1-f) \frac{s^2}{n} = (1-f) \frac{\hat{p}(1-\hat{p})}{n-1}.$$

### Intervalo de confiança

Pelo TLC, temos que

$$\frac{\hat{p} - p}{\sqrt{\frac{N-n}{N-1} \frac{p(1-p)}{n}}} \sim N(0, 1)$$

e um intervalo de confiança de nível de confiança de aproximadamente  $1 - \alpha$  é dado por

$$IC(p, (1 - \alpha)\%) = \left( \hat{p} - z_{\alpha/2} \sqrt{(1-f) \frac{\hat{p}(1-\hat{p})}{n-1}}; \hat{p} + z_{\alpha/2} \sqrt{(1-f) \frac{\hat{p}(1-\hat{p})}{n-1}} \right),$$

como  $\hat{p}(1 - \hat{p}) \leq 1/4$ , um intervalo de confiança conservador é dado por

$$IC(p, (1 - \alpha)\%) = \left( \hat{p} - z_{\alpha/2} \sqrt{\frac{1-f}{4(n-1)}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{1-f}{4(n-1)}} \right),$$

### Tamanho da amostra

Como no caso da média, podemos considerar o tamanho da amostra  $n$ , de tal forma que

$$P(|\hat{p} - p| \leq B) \approx 1 - \alpha,$$

e obtemos um tamanho de amostra dado por

$$n = \frac{N}{\frac{(N-1)D}{p(1-p)+1}}$$

e se considerarmos um cenário mais conservador

$$n = \frac{N}{4(N-1)D + 1},$$

em que  $D = B^2/z_{\alpha/2}^2$ .

### 9. Otimalidade de $\bar{y}$ na AASc

Considere as variáveis  $y_1, \dots, y_n$ , isto é, a variável  $y_i$  assume os valores  $Y_1, \dots, Y_N$ , com probabilidade  $1/N$ , ou seja,  $P(y_i = Y_j) = 1/N, j = 1, \dots, N$ . No plano AASs as variáveis  $y_i$  são independentes.

Estimador linear: um estimador linear de  $\mu$  é uma função  $d_s$  dada por

$$\bar{y}_{sl} = \sum_{i=1}^n l_i y_i,$$

em que os  $l_i$  são constantes conhecidas.

Um estimador  $\bar{y}_{sl}$  é não viciado para  $\mu$  se e somente se

$$\sum_{i=1}^n l_i = 1.$$

Com relação à AASc, na classe dos estimadores lineares não viciados,  $\bar{y}$  é o de menor variância.

## 10. Algoritmos de seleção

### (a) Amostra Aleatória Simples com reposição

#### Algoritmo convencional

1. Sorteamos um elemento de  $\mathcal{U} = \{1, \dots, N\}$  com probabilidade  $1/N$ .

2. Repetimos o procedimento  $n$  vezes

Isso equivale a  $n$  realizações independentes de uma  $Unif(0, 1) : a_1, \dots, a_n$ , de modo que

$$\frac{i-1}{N} < a_i \leq \frac{i}{N} \rightarrow \text{elemento } i \text{ pertence a amostra.}$$

### (b) Amostra Aleatória Simples sem reposição

#### Algoritmo convencional

Sorteamos o  $k$ -ésimo elemento  $k = 1, \dots, n$  com probabilidade  $\frac{1}{N-(k-1)}$  dentre os  $N - (k - 1)$  restantes.

#### Algoritmo de Hajek

1. Associamos a cada elemento de  $\mathcal{U} = \{1, \dots, N\}$  um número pseudo aleatório  $a_i$  por meio de  $N$  realizações independentes de uma  $Unif(0, 1)$ .

2. Ordenamos a população, agora representada pelos pares  $(i, a_i)$  de acordo com  $a_i$ , obtendo uma permutação aleatória.

3. Uma amostra aleatória simples é obtida selecionando  $n$  elementos consecutivos quaisquer nessa permutação.

## 11. Comparação entre AASc e AASs

Quando há dois planos amostrais, é importante saber qual deles é o “melhor”. Como dito anteriormente, o critério mais utilizado em Amostragem é o Erro Quadrático Médio (ou a variância para estimadores não viciados). Sendo assim, trabalharemos com o Efeito do Planejamento (EPA), que compara a variância de um plano qualquer com relação a um plano que é considerado padrão. Considerando AASc e AASs, em ambos os casos,  $\bar{y}$  é um estimador não viciado para  $\mu$ , ou seja,

$$EPA = \frac{Var_{AASs}(\bar{y})}{Var_{AASc}(\bar{y})} = \frac{(1-f)S^2/n}{\sigma^2/n} = \frac{N-n}{N-1}.$$

Quando  $EPA > 1$  temos que o plano no numerador é menos eficiente, quando  $EPA < 1$  temos que o plano no denominador é menos eficiente.

Quando  $EPA = 1$ ?